

Projet : Intelligence artificielle

Sujet : Classification Robuste et Analyse de Décision en Environnement Critique

Dans les scénarios réels (fraude bancaire, diagnostic médical, défaillance industrielle), les classes sont rarement équilibrées. L'objectif de ce projet est de concevoir un système de classification robuste capable de gérer un déséquilibre extrême tout en garantissant des probabilités de prédiction fiables pour la prise de décision, en mettant en valeur les techniques suivantes :

- 1) Feature Engineering avancé : Création de variables, encodage et sélection par importance statistique.
- 2) Optimisation de modèles : Comparaison rigoureuse entre modèles linéaires et modèles d'ensemble (XGBoost/Random Forest).
- 3) Calibration de probabilités : S'assurer que le score de sortie du modèle correspond à une réalité statistique.
- 4) Interprétabilité : Expliquer le "pourquoi" derrière une prédiction.

Livrables :

Étape 1 : Analyse Exploratoire et Préparation (EDA)

- **Analyse de la colinéarité** : Utilisation de la matrice de corrélation et du VIF (*Variance Inflation Factor*).
- **Traitement du déséquilibre** : Comparer au moins deux approches :
 - Niveau algorithmique (poids des classes / *class_weight*).
 - Niveau données (SMOTE, ADASYN ou NearMiss).

Étape 2 : Développement des Modèles

Confronter trois approches mathématiques différentes pour traiter les données. Pour chaque modèle, justifier les hyperparamètres retenus.

1. **Baseline** : Régression Logistique avec Pénalité Élastique (Elastic Net)
2. **Random Forest** avec Analyse de Proximité
 - Entraîner une Forêt Aléatoire et extraire la matrice de proximité (basée sur la fréquence à laquelle deux observations finissent dans la même feuille terminale).
 - Utiliser cette matrice pour détecter des "outliers de prédiction".
 - Livrable attendu : Une visualisation ou une analyse des "outliers de prédiction". expliquer pourquoi le modèle échoue ou hésite sur ces points spécifiques.
3. **Boosting et Apprentissage Sensible au Coût (Cost-Sensitive)**: XGBoost ou LightGBM avec optimisation d'hyperparamètres via Bayesian Search.

- **Gestion du déséquilibre (Cost-Sensitive Learning)** : Contrairement aux approches de rééchantillonnage (SMOTE), vous devrez agir directement sur l'apprentissage. Vous comparerez deux stratégies :
 - L'utilisation du paramètre `scale_pos_weight` pour équilibrer le poids des gradients entre la classe minoritaire et majoritaire.
 - La modification ou la personnalisation de la **fonction de perte (Loss Function)** pour introduire un coût asymétrique lié aux erreurs de classification.
- **Optimisation par Recherche Bayésienne (Optuna)** :

Plutôt qu'un GridSearch exhaustif, vous implémenterez une optimisation basée sur les processus gaussiens ou TPE (*Tree-structured Parzen Estimator*).

- Justification de l'Espace de Recherche : Pour chaque hyperparamètre (ex: `max_depth` entre 3 et 10, `lambda`, `alpha`), vous devrez fournir une justification théorique.
- **Analyse de la Convergence** :

Vous devrez inclure dans votre rapport les graphiques de convergence de l'étude Optuna (*Optimization History* et *Objective Value*) afin de démontrer que l'espace de recherche a été exploré de manière optimale.

Étape 3 : Évaluation et Calibration

- **Métriques avancées** : Ne pas utiliser l'Accuracy. Justifier l'utilisation du score F1-Macro, de la courbe Precision-Recall (AUPRC) et du coefficient de Matthews (MCC).
- **Calibration** : Tracer les Diagrammes de Fiabilité (*Reliability Diagrams*). Si le modèle est mal calibré, appliquer une transformation de Platt Scaling ou une Isotonic Regression.

Étape 4 : Interprétabilité

- Utiliser la bibliothèque SHAP (Shapley Additive Explanations) ou LIME pour identifier les variables qui influencent le plus les prédictions frauduleuses.

Données recommandées

Travailler sur l'une des bases de données suivantes :

- 1) **Credit Card Fraud Detection (Kaggle)** : 284 000 transactions, très déséquilibrée.
- 2) **APS Failure at Scania Trucks (UCI)** : Prédiction de pannes de camions (coût asymétrique entre faux positifs et faux négatifs).